ENSIAS — Université Mohammed V de Rabat
Module : Linked Open Data

Rapport hors séance — TP1

Étude de cas : préparation à l'ouverture liée du jeu de données des établissements de l'enseignement supérieur universitaire public au Maroc (2024-2025)

Module : Linked Open Data
TP : TP1 — Introduction aux données ouvertes liées
Groupe : _____hh_____
Étudiants : BERRI marwa , ZERAIDI yassmine_____
Date : Avril 2026
Encadrant : Pr. Youness BOUTYOUR

1. Introduction

Ce rapport présente le travail hors séance réalisé à l'issue du TP1 du module Linked Open Data. Il porte sur une étude de cas réelle fondée sur le jeu de données officiel des établissements de l'enseignement supérieur universitaire public marocain, publié par le MESRSI sur le portail data.gov.ma sous licence ODbL.

Le jeu de données recense 165 établissements affiliés à 12 universités pour l'année académique 2024-2025, dont 162 établissements de formation et 3 instituts de recherche scientifique. L'objectif de ce travail est d'évaluer la maturité de ce dataset vis-à-vis des principes des Linked Open Data (LOD), d'identifier les entités clés pouvant être alignées avec des référentiels externes reconnus, et de proposer un plan de normalisation préparant une future modélisation RDF.

Trois types d'entités ont été retenus comme prioritaires : les établissements (entités centrales du dataset), les universités (entités hiérarchiques) et les villes (entités géographiques de localisation).

2. Types d'entités étudiés

Les trois types d'entités suivants ont été retenus pour le travail hors séance :

Type d'entité	Exemple local	Raison du choix	Champs can
Établissement	ENSIAS, EMI, FSR	Entité centrale du dataset ; porteur de tous les attributs descriptifs principaux	institution_na year_created
Université	Université Mohammed V (UM5), Hassan II (UH2C)	Entité hiérarchique regroupant plusieurs établissements ; 12 entités stables	institution_na
Ville	Rabat, Casablanca, Fès, Marrakech	Entité géographique transversale ; pivot naturel vers GeoNames	city, country

Ces entités ont été choisies car elles représentent les trois niveaux d'analyse du dataset : l'entité principale (établissement), son conteneur institutionnel (université) et son ancrage territorial (ville). Chacun de ces niveaux dispose de champs exploitables pour un appariement avec des référentiels externes.

3. Benchmark des référentiels externes

3.1 Pour les établissements et les universités : Wikidata vs DBpedia

Critère	Wikidata	DBpedia
Couverture	Très bonne : ENSIAS, EMI, EHTP, UM5 présents avec fiches complètes. Partielle pour les établissements post-2005.	Partielle : uniquement les établissements d'un article Wikipédia complet.
Précision apparente	Élevée : date de fondation, campus, discipline, organisation parente souvent renseignés.	Moyenne : extraction automatique des inf Wikipédia, risque d'erreurs ou d'incomplé
Qualité des identifiants	Excellente : QID stable et déréférençable (ex. Q2963869 pour ENSIAS).	Bonne : URI basée sur le nom Wikipédia, qu'un QID (sensible aux renommages).
Richesse sémantique	Très riche : P571 (fondation), P17 (pays), P131 (localisation), P856 (site web), P749 (organisation parente).	Modérée : dbo:country, dbo:established, disponibles. Moins adaptée aux établisse spécialisés.
Facilité d'utilisation	Bonne : API REST + SPARQL ; recherche multilingue via wbsearchentities (fr, ar, en).	Correcte : endpoint SPARQL disponible, résultats parfois désynchronisés avec Wi

Recommandation	Référentiel principal recommandé pour les entités éducatives marocaines.	Usage secondaire uniquement, pour valid croisée.

3.2 Pour les villes : GeoNames vs Wikidata

Critère	GeoNames	Wikidata
Couverture	Exhaustive : toutes les villes marocaines du dataset référencées.	Très bonne : couvre les 10+ villes prése dataset.
Qualité des identifiants	Excellente : geonames_id numérique stable, URI déréférençable (ex. sws.geonames.org/2538475/).	Excellente : QID stable. Inclut lien direct GeoNames via propriété P1566.
Richesse sémantique	Bonne : noms alternatifs (ar, fr, amazigh), coordonnées GPS, région, population, code pays.	Supérieure : données encyclopédiques, administratif, images, historique.
Facilité d'utilisation	Très bonne : API simple, données librement téléchargeables.	Bonne ; peut servir de pont vers GeoNa P1566.
Recommandation	Référentiel principal pour l'ancrage géospatial.	Référentiel complémentaire pour l'enrich contextuel.

Conclusion : Wikidata est le référentiel de référence pour les entités éducatives, GeoNames est privilégié pour les entités géographiques. Ces deux référentiels sont complémentaires et peuvent être utilisés conjointement dans un graphe LOD.

4. Cas d'appariement manuel

Six cas d'appariement ont été documentés à partir des données du dataset :

#	Entité locale	Référentiel / URI candidate	Indices utilisés	Confiance	Ambiguïté
1	ENSIAS — Rabat	Wikidata Q2963869	Nom complet, sigle ENSIAS, site ensias.um5.ac.ma, ville Rabat	★★★★★	Aucune
2	Université Mohammed V (UM5) — Rabat	Wikidata Q2064250	Nom officiel, sigle UM5, année 1957, ville Rabat	★★★★★	Aucune
3	Cadi Ayyad University (UCA) — Marrakesh	Wikidata Q928670	Nom anglais, sigle UCA, ville Marrakech, année 1978	★★★★☆	Variation de translittérat : Cadi / Qadi Ayyad
4	Ecole Hassania des Travaux Publics (EHTP) — Casablanca	Wikidata Q3057282	Nom complet, sigle EHTP, ville Casablanca, domaine génie civil	★★★★☆	Aucune notable
5	Rabat (ville)	GeoNames 2538475	Nom de ville, code pays MA	★★★★★	Autres villes nommées Rabat dans le monde ; levée par countryCode=MA
6	Marrakesh (ville)	GeoNames 2542997	Nom de ville, code pays MA	★★★★★	Orthographe : Marrakes vs Marrakech — les deu formes présentes dans GeoNames

5. Plan de normalisation et d'identification

5.1 Valeurs à normaliser

Champ	Problème observé	Règle de normalisation proposée	Impact pour le LOD
institution_name	Absence d'accents ; mélange français/anglais (ex. Cadi Ayyad University)	Standardiser en français officiel avec accents ; ajouter labels arabe et anglais comme skos:altLabel	Meilleur appariement Wikidata cohérence inter-enregistrement
short_name	Espaces dans le sigle (ex. 'ENSA Kenitra')	Normaliser en sigle pur sans espace : ENSA-Kenitra (avec tiret) pour usage dans les URIs	Composant d'URI fiable et sans ambiguïté
city	Variantes orthographiques : Marrakesh / Marrakech, Tetouan / Tétouan	Adopter la forme française officielle avec accents ; créer une table de correspondance locale → URI GeoNames	Alignement géographique exac interopérabilité internationale
institution_type	Valeurs hétérogènes en anglais non normalisées	Mapper vers schema.org EducationalOrganization ou thésaurus SKOS local ; documenter le mapping	Interopérabilité sémantique dan graphe RDF
main_field	Valeurs non contrôlées (computer science, data science, applied sciences)	Aligner vers ISCED-F 2013 ; créer des URIs locaux pour les disciplines non couvertes	Lien vers thésaurus disciplinair international
year_created	Entier simple, non conforme à RDF	Convertir en xsd:gYear (ex. "1992"^^xsd:gYear)	Requêtes temporelles SPARQL précises
country	Texte 'Morocco' uniquement, sans URI	Remplacer par URI stable : Wikidata Q1028 ou code ISO 3166-1 MA	Alignement pays international ; suppression de l'ambiguïté linguistique

5.2 Entités devant recevoir un identifiant stable

En l'absence d'identifiant officiel MESRSI dans le dataset, la stratégie suivante est proposée :

Entité cible	Base de construction de l'URI locale	Exemple	Risque
Établissement	http://data.education.ma/etablissement/{sigle}-{ville}	/etablissement/ENSIAS-Rabat	Collision si même sigle deux villes différentes
Université	http://data.education.ma/universite/{sigle}	/universite/UM5	Instabilité si renommage compléter avec owl:sam QID Wikidata
Ville	URI GeoNames externe : http://sws.geonames.org/{id}/	geonames.org/2538475/	Dépendance à un servic prévoir copie locale si n
Discipline	http://data.education.ma/discipline/{label-normalise}	/discipline/informatique	Doublons si normalisati textuelle insuffisante

Ces identifiants locaux doivent être complétés par des liens owl:sameAs vers Wikidata et GeoNames pour assurer l'interopérabilité avec le Web des données. Sans infrastructure Web déployée, les URIs locaux ne seront pas déréférençables à ce stade.

6. Analyse des risques

Risques de faux appariement

Le risque principal concerne les établissements portant un nom générique, comme 'Faculté des Sciences', présents dans plusieurs villes différentes. Un appariement basé sur le seul nom sans contrainte géographique aboutirait à de fausses correspondances. Il est donc impératif de toujours combiner le nom de l'établissement avec la ville et, si disponible, l'année de création pour lever l'ambiguïté.

Cas de désambiguïsation

Les universités portant des noms similaires (Hassan I de Settat, Hassan II de Casablanca) doivent être distinguées par leur ville d'implantation et leur année de création. Wikidata permet cette désambiguïsation précise grâce aux propriétés P131 (localisation administrative) et P571 (date de fondation).

Limites des référentiels choisis

Wikidata est incomplète pour les établissements créés après 2005 (ex. ENSA Kénitra, créée en 2008). DBpedia est trop dépendant de la qualité des articles Wikipédia en français. GeoNames ne couvre pas les établissements d'enseignement, uniquement les entités géographiques. Aucun de ces référentiels ne dispose d'un identifiant officiel marocain de type 'numéro d'accréditation MESRSI'.

Informations manquantes dans le dataset

- Identifiant officiel MESRSI : absence d'un code administratif national stable.
- Région administrative : absente du dataset ; essentielle pour un alignement géographique précis.
- Coordonnées GPS : aucune coordonnée fournie pour les établissements.
- Noms en arabe : absents, ce qui limite l'alignement avec des sources arabophones.
- Nombre d'étudiants ou de filières : informations utiles pour un enrichissement sémantique.

7. Difficultés rencontrées

La première difficulté est l'absence totale d'identifiants stables dans le dataset source. Le champ record_id est un simple numéro séquentiel sans signification externe, ce qui rend tout alignement automatisé impossible sans étape préalable de construction d'URI.

La qualité insuffisante de certains champs textuels constitue un second obstacle majeur : l'absence d'accents, les variantes orthographiques des noms de villes, et la coexistence de deux langues (français et anglais) dans le même champ ralentissent la phase de recherche et de validation dans Wikidata ou DBpedia.

La couverture partielle de Wikidata pour les établissements spécialisés récents impose de recourir à des critères d'appariement moins directs (site web officiel, sigle, ville), réduisant le niveau de confiance des correspondances établies.

Enfin, l'absence de région administrative dans le dataset empêche une localisation précise des établissements au-delà de la ville, ce qui complique l'alignement avec les référentiels géographiques.

8. Conclusion

Cette étude préparatoire montre que le jeu de données MESRSI constitue une base solide et pertinente pour une future publication en Linked Open Data, mais que plusieurs conditions doivent être remplies en amont.

Sur le plan de la normalisation, les champs textuels doivent être homogénéisés (accents, langue unique, noms officiels), et les types doivent être alignés vers des ontologies contrôlées. Sur le plan des identifiants, la construction d'URIs locaux combinant sigle et ville offre une solution pragmatique, à compléter obligatoirement par des liens owl:sameAs vers Wikidata et GeoNames.

Sur le plan de l'enrichissement, Wikidata s'impose comme référentiel principal pour les entités éducatives, GeoNames pour les villes. Les six cas d'appariement documentés dans ce rapport illustrent la faisabilité de l'alignement manuel et posent les bases d'une stratégie semi-automatisée exploitable lors du TP2.

En résumé, ce dataset atteint actuellement 3 étoiles dans le modèle de Tim Berners-Lee (données disponibles sur le Web, structurées, en format non propriétaire) mais ne franchit pas les niveaux 4 et 5 faute d'URIs stables et de liens externes. Le plan de normalisation proposé constitue la feuille de route technique pour atteindre ces niveaux lors du TP2.

Annexes

Annexe A — Extrait du jeu de données source (sample)

record_id	institution_name	short_name	city	institution_type	year_created
1	Ecole Nationale Superieure d'Informatique et d'Analyse des Systemes	ENSIAS	Rabat	public school	1992
2	Ecole Mohammadia d'Ingenieurs	EMI	Rabat	public school	1959
4	Universite Mohammed V in Rabat	UM5	Rabat	university	1957
7	Cadi Ayyad University	UCA	Marrakesh	university	1978
8	Ecole Hassania des Travaux Publics	EHTP	Casablanca	engineering school	1971
9	Universite Hassan II de Casablanca	UH2C	Casablanca	university	1975

Annexe B — Schéma conceptuel des liens (Mermaid)

Le schéma suivant illustre les liens entre les entités locales et les référentiels externes :

```
Établissement --> Université (affiliation)
Établissement --> Ville (localisation)
Université -.-> Wikidata (owl:sameAs)
Ville -.-> GeoNames (owl:sameAs)
```