ENSIAS — Université Mohammed V de Rabat
Module : Linked Open Data — TP1

Rapport hors séance — TP1

Étude de cas : préparation à l'ouverture liée du jeu de données des établissements de l'enseignement supérieur universitaire public au Maroc (2024-2025)

Module : Linked Open Data
TP : TP1 — Introduction aux données ouvertes liées
Groupe : hh
Date : 18 avril 2026
Encadrant : Pr. Youness BOUTYOUR
Source : MESRSI — data.gov.ma — Universités Publiques 2024-2025.xlsx

1. Introduction

Ce rapport constitue le travail hors séance demandé à l'issue du TP1. Il s'appuie sur le fichier officiel publié par le MESRSI sur le portail data.gov.ma sous licence ODbL : Universités Publiques 2024-2025.xlsx. Ce fichier contient une feuille unique intitulée « Universités Publiques » et dispose de 10 colonnes : Université, Établissement, Abréviation, Effectifs 2023-2024, Nom arabe de l'établissement, Nom arabe de l'université, Ville, Adresse, Téléphone, Fax.

Le jeu de données recense 165 établissements affiliés à 12 universités publiques, répartis dans 38 villes à travers tout le territoire marocain, de Dakhla au nord de Berkene, en passant par Agadir, Marrakech, Fès et Rabat. Il dénombre au total plus d'un million d'étudiants inscrits pour l'année 2023-2024.

Un atout majeur de ce dataset réel, absent du fichier pédagogique utilisé en séance, est la présence des noms en arabe pour 100 % des enregistrements — aussi bien pour les établissements que pour les universités. En revanche, plusieurs éléments présents dans le CSV pédagogique sont absents ici : aucun site web, aucune date de création, aucun domaine de formation, aucun identifiant stable.

L'objectif de ce travail est d'évaluer la maturité LOD de ce dataset, d'identifier les entités clés, de les aligner avec des référentiels externes (Wikidata, GeoNames), et de proposer un plan de normalisation préparant une future modélisation RDF lors du TP2.

2. Types d'entités étudiés

Trois types d'entités ont été identifiés directement à partir de l'analyse du fichier XLSX réel :

Type d'entité	Exemple tiré du fichier réel	Raison du choix	C
Établissement	Ecole Mohammadia d'Ingénieurs Rabat	Entité centrale ; 165 enregistrements avec nom, abréviation, adresse, effectifs et nom arabe	E A
Université	Université Mohammed V - Rabat	Entité hiérarchique ; 12 universités nommées en français et en arabe ; structure le dataset	U
Ville	Fès, Béni Mellal, Dakhla, Es-Semara	Entité géographique ; 38 villes distinctes ; présente dans chaque enregistrement	V

Ces entités constituent les trois niveaux d'analyse du dataset : l'entité principale (établissement), son conteneur institutionnel (université) et son ancrage territorial (ville). Les noms en arabe disponibles pour les deux premières catégories représentent un avantage concret pour la vérification des appariements avec Wikidata, dont les labels arabes sont souvent renseignés.

3. Benchmark des référentiels externes

3.1 Établissements et universités : Wikidata vs DBpedia

Critère	Wikidata	DBpedia
Couverture	Bonne pour les grandes écoles nationales (EMI, ENSIAS, ENSAM, ENCG). Faible pour les facultés génériques (FSJES, FLSH) démultipliées dans de nombreuses villes.	Très partielle : seules les universités-m Wikipédia complète. Les 165 composa pas référencées individuellement.
Précision	Élevée pour les établissements à nom distinctif. Faible pour les facultés polydisciplinaires récentes (post-2007) souvent absentes.	Faible : extraction automatique d'infob souvent incomplètes pour les composa
Qualité des identifiants	Excellente : QID stable et déréférençable (ex. Q2963869 pour ENSIAS). Les noms arabes du dataset facilitent la vérification des labels ar: de Wikidata.	Moyenne : URI basée sur le titre Wikip renommages. Pas de label arabe syste
Richesse sémantique	Très riche : P571 (fondation), P17 (pays), P131 (localisation), P856 (site web), P749 (organisation parente), P527 (composantes).	Limitée : dbo:country, dbo:city, dbo:est uniquement pour les grandes universit
Limites spécifiques à ce dataset	Les abréviations contiennent la ville en suffixe (ex. « ENSIAS Rabat ») — nettoyage obligatoire avant appariement. Absence du champ website dans le dataset réel limite les vérifications.	Non adapté aux composantes universi écoles, instituts) qui forment la quasi-to enregistrements.
Recommandation	✅Référentiel principal	□ Usage secondaire uniquement

3.2 Villes : GeoNames vs Wikidata

Critère	GeoNames	Wikidata
Couverture	Exhaustive : toutes les 38 villes du dataset (y compris Berkene, Dakhla, Es-Semara, Kssar El Kébir, Sidi Bennour) sont référencées.	Très bonne pour les grandes villes ; co secondaires.
Qualité des identifiants	Excellente : geonames_id stable ; URI déréférençable http://sws.geonames.org/{id}/	Excellente : QID stable + lien P1566 —
Richesse sémantique	Bonne : noms en français, arabe, amazigh ; coordonnées GPS ; région administrative. La forme française avec accents du dataset (Fès, Béni Mellal, Tétouan) correspond aux formes GeoNames.	Supérieure sur le plan encyclopédique vers GeoNames via P1566.
Erreur détectée	La valeur « FEG Guelmim » apparaît dans le champ Ville (ligne 145) au lieu de « Guelmim » — confusion avec l'abréviation de l'établissement. À corriger avant appariement.	—
Recommandation	✅Référentiel principal géographique	□ Complémentaire

4. Cas d'appariement manuel

Six cas d'appariement ont été documentés à partir des données réelles du fichier XLSX :

#	Entité locale (dataset réel)	Référentiel / URI	Indices utilisés	Confiance	Ambiguïté
1	Ecole Nationale Supérieure d'Informatique et d'Analyse des Systèmes Rabat	Wikidata Q2963869	Nom complet + abréviation « ENSIAS Rabat » + ville Rabat + nom arabe المدرسة الوطنية العليا للإعلاميات	★★★★★	Aucune
2	Université Mohammed V - Rabat	Wikidata Q2064250	Nom officiel + ville Rabat + nom arabe جامعة محمد الخامس	★★★★★	Aucune
3	Université Hassan II - Casablanca	Wikidata Q3552327	Nom + ville Casablanca + nom arabe جامعة الحسن الثاني	★★★★☆	À distinguer de l Université Hass Mohammedia (fu

					2014) — vérifier création Wikidat
4	Ecole Nationale de Commerce et de Gestion Agadir	Wikidata Q22679872	Nom complet + abréviation ENCG + ville Agadir + université Ibn Zohr	★★★★☆	Plusieurs ENCG dataset (Agadir, Fès, Marrakech, Tanger...) — le s ENCG ne suffit p
5	Rabat (ville)	GeoNames 2538475	Nom de ville + code pays MA + capitale du Maroc	★★★★★	Aucune avec filt countryCode=M
6	Fès (ville)	GeoNames 2295420	Nom avec accent présent dans le dataset + code pays MA	★★★★★	Forme anglaise certains contexte la forme français

5. Plan de normalisation et d'identification

5.1 Champs prioritaires à normaliser

Champ	Problème observé (données réelles)	Règle proposée	Impact LOD
Abreviation	Contient systématiquement la ville en suffixe (« ENSIAS Rabat », « ENSA Béni Mellal » avec double espace). Inutilisable directement comme identifiant.	Extraire le sigle pur par suppression du suffixe ville. Supprimer les espaces multiples. Stocker dans un nouveau champ sigle_pur.	Rend le sigle utili composant d'URI d'appariement W
Universite	Nom avec tirets et espaces parasites en fin de chaîne : « Université Mohammed V - Rabat - ».	Supprimer les tirets finaux et espaces parasites. Extraire la ville-siège dans un champ séparé ville_siege.	Nom propre exploi rdfs:label. Facilite
Ville	Erreur de saisie confirmée ligne 145 : « FEG Guelmim » au lieu de « Guelmim ».	Corriger manuellement. Créer une table de correspondance ville → GeoNames ID pour les 38 villes.	Alignement géog faux positif.
Etablissement_AR / Universite_AR	Présents pour 100% des enregistrements — atout majeur non exploité à ce stade.	Nettoyer les espaces parasites éventuels. Utiliser comme rdfs:label @ar dans le graphe RDF.	Enrichissement s immédiat. Facilite appariements Wi
Adresse	9 adresses manquantes. Format non uniforme (présence ou absence du code postal).	Signaler les manquants. Normaliser : Rue, Quartier, CP, Ville.	Permettra un géo les coordonnées
Effectifs_2023_2024	5 valeurs manquantes (IS Rabat, IERA Rabat, IUEAEMIA Rabat, EST Tétouan, EST Ouarzazate).	Signaler comme absents. Ne pas mettre 0 — utiliser xsd:integer sans valeur.	Évite les faux zér SPARQL agrégé

5.2 Stratégie d'identifiants et schéma URI

En l'absence de tout identifiant officiel MESRSI dans le fichier, la stratégie suivante est proposée :

Entité	URI locale proposée	Exemple concret	Risque
Établissement	http://data.education.ma/etablissement/{sigle-pur}-{ville}	/etablissement/ENSIAS-Rabat	Unicité à vérifier ENSA Khouribga /etablissement/E /etablissement/E
Université	http://data.education.ma/universite/{sigle}	/universite/UM5	Sigle à dériver du obligatoirement o Wikidata
Ville	http://sws.geonames.org/{id}/ (externe)	http://sws.geonames.org/2538475/ (Rabat)	Dépendance à un table de correspo
Pays Maroc	Wikidata Q1028 ou ISO 3166-1 MA	https://www.wikidata.org/wiki/Q1028	Aucun

6. Analyse des risques

Problème structurel principal : abréviations composites

Le problème le plus critique identifié dans le dataset réel est le format des abréviations. Contrairement au CSV pédagogique où « ENSIAS » était un sigle propre, le fichier MESRSI utilise « ENSIAS Rabat », « FSJES Agdal Rabat », « ENSA Béni Mellal » (avec double espace). Ces valeurs composites ne peuvent être utilisées ni comme identifiants, ni comme clés d'appariement sans une extraction préalable du sigle pur.

Risques de faux appariement

Les sigles génériques ENS, ENSA, ENCG, EST, FSJES, FLSH, FMP sont présents dans de nombreuses villes. Un alignement automatique sur le sigle seul produirait des faux positifs massifs. La combinaison sigle-pur + ville est obligatoire pour lever l'ambiguïté. Par exemple, il existe dans le dataset : ENSA Fès, ENSA Oujda, ENSA Tanger, ENSA Tétouan, ENSA Al Hoceima, ENSA Agadir, ENSA El Jadida, ENSA Berrechid, ENSA Béni Mellal, ENSA Khouribga.

Désambiguïsation des universités

L'Université Hassan II de Casablanca (présente dans le dataset) doit être distinguée de l'ancienne Université Hassan II de Mohammedia (fusionnée en 2014 avec l'Université Hassan II de Casablanca). Wikidata permet cette désambiguïsation via la propriété P571 (date de fondation) et P131 (localisation).

Limites des référentiels

- Wikidata : incomplète pour les établissements créés après 2007 et pour les facultés polydisciplinaires délocalisées.
- GeoNames : ne référence pas les établissements d'enseignement, uniquement les entités géographiques.
- DBpedia : non adapté aux composantes universitaires (facultés, instituts) qui forment la majorité des 165 enregistrements.
- Aucun référentiel ne contient le numéro d'accréditation officiel MESRSI.

Informations manquantes dans le dataset réel

- Aucun site web : champ absent du fichier MESRSI, contrairement au CSV pédagogique — perte de la meilleure ancre d'appariement.
- Aucune date de création des établissements.
- Aucun domaine de formation (main_field).
- Aucun identifiant administratif officiel (code MESRSI).
- Aucune coordonnée GPS — l'adresse postale est présente mais non géocodée.

7. Difficultés rencontrées

La principale difficulté est structurelle : les abréviations du dataset réel ne sont pas des sigles purs mais des compositions sigle + ville (« ENSIAS Rabat », « ENSA Fès »). Cette structure, probablement choisie pour éviter l'ambiguïté dans le tableau Excel, rend toute utilisation directe en tant qu'identifiant ou clé d'appariement impossible sans une étape de nettoyage textuel.

La seconde difficulté tient à l'absence du champ website dans le dataset réel, alors que ce champ était la meilleure ancre d'appariement dans le CSV pédagogique de la séance. L'appariement repose donc uniquement sur le nom de l'établissement, la ville et le nom arabe — trois critères suffisants pour les grands établissements, mais fragiles pour les facultés génériques.

La troisième difficulté est l'erreur de saisie détectée ligne 145, où la valeur « FEG Guelmim » apparaît dans le champ Ville au lieu de « Guelmim ». Cette erreur illustre le besoin d'une validation systématique des valeurs de chaque colonne avant tout alignement automatisé.

Enfin, la profusion de sigles génériques (plus de 10 ENSA, plus de 10 ENCG, plus de 10 EST...) rend le benchmark d'appariement plus complexe que prévu et impose une stratégie de désambiguïsation systématique par ville pour chaque type d'établissement.

8. Conclusion

Cette étude préparatoire sur le dataset réel MESRSI révèle à la fois un potentiel important et des lacunes structurelles significatives pour une publication en Linked Open Data.

Le potentiel tient à la richesse du contenu : 165 établissements couvrant l'ensemble du territoire marocain, les effectifs étudiants réels, et surtout la présence des noms en arabe pour 100% des enregistrements — un atout rare qui facilitera les appariements multilingues avec Wikidata.

Les lacunes sont également réelles : absence d'identifiants stables, d'URLs de sites web, de dates de création, de domaines de formation et de coordonnées GPS. Le format composite des abréviations (sigle + ville) constitue le problème technique le plus immédiat à résoudre avant toute modélisation RDF.

En termes de maturité LOD, ce dataset atteint 2 à 3 étoiles : données disponibles sur le Web (portail data.gov.ma), structurées (format XLSX/CSV), en format exploitable — mais sans URIs (niveau 4) ni liens vers des référentiels externes (niveau 5). Le plan de normalisation proposé — extraction des sigles purs, alignement GeoNames pour les villes, alignement Wikidata pour les universités et les grandes écoles — constitue la feuille de route technique pour franchir ces deux niveaux lors du TP2.

Annexes

Annexe A — Statistiques clés du dataset réel

Indicateur	Valeur
Total établissements	165
Universités publiques	12
Villes couvertes	38
Total étudiants (2023-2024)	1 106 225
Effectifs min / max	60 (ENSIASD Taroudant) / 43 097 (FSJES Marrakech)
Effectifs manquants	5 enregistrements (IS Rabat, IERA Rabat, IUEAEMIA Rabat, EST Tétoua
Noms arabes disponibles	165 / 165 (100 %)
Adresses manquantes	9
Téléphones manquants	10
Erreur de saisie détectée	1 (ligne 145 : « FEG Guelmim » dans le champ Ville)

Annexe B — Extrait du fichier réel (5 premiers enregistrements)

Université	Établissement	Abréviation	Ville
Université Mohammed V - Rabat	Faculté des Sciences Juridiques, Economiques et Sociales Agdal Rabat	FSJES Agdal Rabat	Rabat
Université Mohammed V - Rabat	Faculté des Lettres et des Sciences Humaines Rabat	FLSH Rabat	Rabat
Université Mohammed V - Rabat	Ecole Mohammadia d'Ingénieurs Rabat	EMI Rabat	Rabat
Université Mohammed V - Rabat	Ecole Nationale Supérieure d'Informatique et d'Analyse des Systèmes Rabat	ENSIAS Rabat	Rabat
Université Hassan II - Casablanca	Faculté des Sciences Juridiques, Economiques et Sociales Aïn Chock Casablanca	FSJES Aïn Chock Casablanca	Casablan

Annexe C — Table de correspondance villes → GeoNames (10 villes prioritaires)

Ville (dataset)	GeoNames ID	URI déréférençable
Rabat	2538475	http://sws.geonames.org/2538475/
Casablanca	2553604	http://sws.geonames.org/2553604/
Fès	2295420	http://sws.geonames.org/2295420/
Marrakech	2542997	http://sws.geonames.org/2542997/
Agadir	2510852	http://sws.geonames.org/2510852/
Tanger	2530335	http://sws.geonames.org/2530335/
Meknès	2542083	http://sws.geonames.org/2542083/
Oujda	2534906	http://sws.geonames.org/2534906/
Kénitra	2542496	http://sws.geonames.org/2542496/
Tétouan	2527089	http://sws.geonames.org/2527089/